

BÁO CÁO MÔN HỌC

PHÁT TRIỂN CÁC HỆ THỐNG THÔNG MINH Assignment 02: End-to-End Machine Learning Systems

Họ và tên sinh viên:	Trần Văn Hậu
Mã sinh viên:	B23DCCN287
Lớp học phần:	D23CQCN01-B
Giảng viên hướng dẫn:	PGS. TS. Trần Đình Quế

1. Tóm tắt Thực hiện & Tổng quan Kiến trúc Hệ thống

Trong khuôn khổ học phần Phát triển các hệ thống thông minh (Assignment 02), báo cáo này trình bày toàn diện quá trình nghiên cứu, xây dựng và hoàn thiện ba hệ thống học máy thông minh độc lập phục vụ ba miền ứng dụng thực tế khác nhau: Y tế (Chẩn đoán nguy cơ Tiểu đường), Bất động sản (Định giá nhà ở Hà Nội) và Thương mại điện tử (Phân loại hành vi & khuyến nghị sản phẩm).

Cơ sở toán học: Cả ba hệ thống đều được phát triển dựa trên nguyên lý cốt lõi của Machine Learning hiện đại: chuyển đổi thực thể thế giới thực thông qua hàm ánh xạ biểu diễn dữ liệu vào không gian Euclid đa chiều:

$$\mathbf{x} = \phi(\text{raw_instance}) \in \mathbb{R}^d, \quad \mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N \subset \mathbb{R}^d \times \mathcal{Y}$$

Toàn bộ quy trình từ tiền xử lý (Scaling, One-Hot Encoding, TF-IDF Vectorization), huấn luyện mô hình, đánh giá đa tiêu chuẩn, đóng gói Pipeline artifact đến xây dựng REST API Backend (FastAPI) và giao diện Web/Mobile tương tác thời gian thực đều được thực hiện nghiêm ngặt, tuân thủ nguyên tắc phòng chống rò rỉ thông tin (Data Leakage Prevention).

Hệ thống thông minh	Bản chất bài toán	Biểu diễn số học $\mathbf{x}_i$	Mô hình tối ưu lựa chọn	Hiệu năng kiểm thử chính	FastAPI Endpoint
1. Diabetes Screening	Phân loại nhị phân (Binary)	$\mathbf{x} \in \mathbb{R}^{15}$ (Z-Score + OHE)	Random Forest Classifier	Accuracy: 91.74%	POST /predict GET /health

				ROC-AUC: 0.9738	
2. House Price Valuation	Hồi quy liên tục (Regression)	$x \in \mathbb{R}^{55}$ (RobustScaler + OHE)	Random Forest Regressor	MAE: 23.34 tr/m ² R ² : 0.3729	POST /predict GET /health
3. Customer Recommendation	Phân loại đa phương thức (Multimodal)	$x \in \mathbb{R}^{1,038}$ (TF-IDF + Tabular)	Logistic Regression (Balanced)	Accuracy: 93.33% ROC-AUC: 0.9772	POST /predict GET /health

2. Ứng dụng 1: Hệ thống Sàng lọc & Dự đoán Nguy cơ Tiểu đường (Diabetes Prediction)

Link GitHub Notebook:

https://github.com/TrVHau/A2_CT_hautv.287/blob/main/diabetes/notebook/diabetes_prediction.ipynb

Link Kaggle Dataset: <https://www.kaggle.com/datasets/iammustafatz/diabetes-prediction-dataset>


2.1. Định nghĩa bài toán và Phân tích Dữ liệu Nguồn

Mục tiêu bài toán là hỗ trợ sàng lọc sớm nguy cơ mắc bệnh tiểu đường dựa trên các chỉ số sinh học và thói quen sinh hoạt của bệnh nhân. Đây là bài toán Phân loại nhị phân có giám sát với nhãn mục tiêu $y \in \{0, 1\}$ (0: Không mắc bệnh, 1: Mắc bệnh tiểu đường).

Bộ dữ liệu Diabetes Prediction Dataset thu thập 100,000 bản ghi bệnh nhân thực tế. Qua kiểm định chất lượng dữ liệu, nhóm đã loại bỏ 3,552 bản ghi trùng lặp (giữ lại 96,448 quan sát duy nhất), xác nhận không có giá trị khuyết thiếu (0 missing values), kiểm tra dải giá trị sinh lý hợp lệ (Glucose: 80-300 mg/dL, HbA1c: 3.5-9.0%, BMI: 10.0-80.0 kg/m²). Phân phối nhãn cho thấy mức độ mất cân bằng lớp rõ rệt: 91.5% nhãn 0 và 8.5% nhãn 1.

Tên thuộc tính	Kiểu dữ liệu	Miền giá trị	Vai trò & Phương pháp tiền xử lý
age	Số thực (float)	0.08 – 80.0 tuổi	Đặc trưng liên tục; Chuẩn hóa StandardScaler
bmi	Số thực (float)	10.01 – 80.0 kg/m ²	Chỉ số khối cơ thể; Chuẩn hóa StandardScaler
HbA1c_level	Số thực (float)	3.5 – 9.0 %	Tỷ lệ đường gắn Hemoglobin; Chuẩn hóa StandardScaler
blood_glucose_level	Số nguyên (int)	80 – 300 mg/dL	Đường huyết ngẫu nhiên; Chuẩn hóa StandardScaler

hypertension	Nhị phân (int)	0 hoặc 1	Tiền sử cao huyết áp; Chuẩn hóa StandardScaler
heart_disease	Nhị phân (int)	0 hoặc 1	Tiền sử bệnh tim; Chuẩn hóa StandardScaler
gender	Định danh (str)	Female, Male, Other	Biến phân loại; Mã hóa OneHotEncoder
smoking_history	Định danh (str)	never, current, former, ...	Lịch sử hút thuốc; Mã hóa OneHotEncoder
diabetes	Nhị phân (int)	0 hoặc 1	Biến mục tiêu giám sát (Target class)



Hình: Phân phối nhãn mục tiêu diabetes và tỷ lệ mất cân bằng dữ liệu (100k quan sát)

2.2. Biểu diễn Không gian Đặc trưng & Pipeline Tiền xử lý

Mỗi bệnh nhân i được biểu diễn bởi một vector đặc trưng duy nhất trong không gian Euclid 15 chiều:

$$\mathbf{x}_i = [z(\text{age}), z(\text{bmi}), z(\text{HbA1c}), z(\text{glucose}), z(\text{hyper}), z(\text{heart}), \mathbf{e}_{\text{gender}}, \mathbf{e}_{\text{smoke}}]^T \in \mathbb{R}^{15}$$

Dữ liệu được phân chia ngẫu nhiên có bảo toàn tỷ lệ lớp (Stratified 80/20 Train-Test Split), tạo ra tập huấn luyện $X_{\text{train}} \in \mathbb{R}^{(77,158 \times 15)}$ và tập kiểm định độc lập $X_{\text{test}} \in \mathbb{R}^{(19,290 \times 15)}$. Toàn bộ tham số thống kê (mean, std) của bộ chuẩn hóa và từ điển mã hóa OHE chỉ được học trên X_{train} để triệt tiêu hoàn toàn Data Leakage.

❏ **Code Snippet: Xây dựng ColumnTransformer Preprocessing Pipeline cho Diabetes**

```
# Pipeline tiền xử lý và Vector hóa đặc trưng Diabetes
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.pipeline import Pipeline
from sklearn.ensemble import RandomForestClassifier


num_features = ['age', 'bmi', 'HbA1c_level', 'blood_glucose_level', 'hypertension',
                'heart_disease']
cat_features = ['gender', 'smoking_history']
```

```
preprocessor = ColumnTransformer(  
    transformers=[  
        ('num', StandardScaler(), num_features),  
        ('cat', OneHotEncoder(handle_unknown='ignore', sparse_output=False), cat_features)  
    ]  
)  
  
# Đóng gói Pipeline hoàn chỉnh chống Data Leakage  
diabetes_pipeline = Pipeline(steps=[  
    ('preprocessor', preprocessor),  
    ('classifier', RandomForestClassifier(n_estimators=100, max_depth=12,  
                                        class_weight='balanced', random_state=42, n_jobs=-1))  
)
```

2.3. Thực nghiệm, Đánh giá So sánh & Lựa chọn Mô hình

Nhóm đã tiến hành thử nghiệm đối chiếu 6 thuật toán học máy phổ biến trên cùng tập kiểm thử độc lập X_test (19,290 mẫu). Do nhãn mục tiêu mất cân bằng, chỉ số Accuracy thông thường không phản ánh chính xác rủi ro; mô hình tối ưu cần tối đa hóa khả năng phát hiện ca bệnh (Recall) kết hợp độ hài hòa F1-Score và phân tích xác suất ROC-AUC:

Thuật toán (Mô hình)	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Random Forest (Selected)	0.9174	0.5189	0.8679	0.6495	0.9738
Decision Tree (Tối ưu độ sâu)	0.8806	0.4189	0.9151	0.5747	0.9704
SVM (LinearSVC Calibrated)	0.9588	0.8604	0.6362	0.7315	0.9600
K-Nearest Neighbors (K=11)	0.9602	0.9167	0.6032	0.7276	0.9294
Logistic Regression	0.8846	0.4253	0.8797	0.5734	0.9601
Dummy Classifier (Baseline)	0.9150	0.0000	0.0000	0.0000	0.5000



Hình: So sánh hiệu năng 6 mô hình phân loại Tiểu đường trên tập Test

Kết luận lựa chọn mô hình: Quyết định lựa chọn: Random Forest Classifier được chọn làm mô hình chính thức nhờ đạt chỉ số tổng hợp Composite Score cao nhất (0.8193), khả năng bao quát ca bệnh Recall

= 86.79% (nhận diện chính xác 86.8% bệnh nhân có nguy cơ), ROC-AUC xuất sắc đạt 0.9738 và hạn chế tối đa nguy cơ chẩn đoán sót (False Negatives). Toàn bộ pipeline được lưu trữ thành file nhị phân `diabetes\_pipeline.joblib` (dung lượng 18.3 MB).

2.4. Triển khai REST API Backend & Giao diện Ứng dụng

Hệ thống được đóng gói thành dịch vụ web hiệu năng cao bằng FastAPI. API nạp trực tiếp file `diabetes\_pipeline.joblib`, nhận payload JSON từ Client, xác thực kiểu dữ liệu qua Pydantic và thực hiện suy luận thời gian thực:

❏ Code Snippet: Triển khai REST API dự đoán nguy cơ Tiểu đường với FastAPI

```
# Trích đoạn Backend FastAPI triển khai Diabetes Prediction
from fastapi import FastAPI
from pydantic import BaseModel, Field
import joblib, pandas as pd

app = FastAPI(title="Diabetes Risk Prediction API")
pipeline = joblib.load("models/diabetes_pipeline.joblib")

class PatientInput(BaseModel):
    gender: str = Field(..., example="Male")
    age: float = Field(..., ge=0, le=120)
    hypertension: int = Field(..., ge=0, le=1)
    heart_disease: int = Field(..., ge=0, le=1)
    smoking_history: str = Field(..., example="former")
    bmi: float = Field(..., ge=10.0, le=80.0)
    HbA1c_level: float = Field(..., ge=3.0, le=15.0)
    blood_glucose_level: int = Field(..., ge=50, le=500)

@app.post("/predict")
def predict_diabetes_risk(data: PatientInput):
    df_in = pd.DataFrame([data.dict()])
    prob = pipeline.predict_proba(df_in)[0]
    pred_label = int(prob[1] >= 0.40) # Ngưỡng tối ưu Recall
    return {
        "prediction": pred_label,
        "risk_level": "Nguy cơ cao" if pred_label == 1 else "Nguy cơ thấp",
        "probability_diabetic": float(prob[1]),
        "probability_healthy": float(prob[0])
    }
```

Diabetes Prediction

Gender

Male

Age (years)

62

Hypertension

Yes

Heart Disease

Yes

Smoking History

Former

BMI (Body Mass Index)

33.8

HbA1c Level (%)

7.8

Blood Glucose Level (mg/dL)

210

Hình: Giao diện Web Client: Form nhập liệu 8 chỉ số lâm sàng (Chụp thực tế từ App đang chạy)

Male

Age (years)

62

Hypertension

Yes

Heart Disease

Yes

Smoking History

Former

BMI (Body Mass Index)

33.8

HbA1c Level (%)

7.8

Blood Glucose Level (mg/dL)

210

Predict Diabetes Risk

⚠️ High Risk of Diabetes

Hình: Giao diện Web Client: Hiển thị kết quả đánh giá nguy cơ và phân phối xác suất thời gian thực

Diabetes Prediction

Gender

Female



Age (years)

58

Hypertension

Yes



Heart Disease

No



Smoking History

Never



BMI (Body Mass Index)

31.2

HbA1c Level (%)

Hình: Giao diện Mobile Client: Nhập liệu trên điện thoại di động (Chụp thực tế)

Female



Age (years)

58

Hypertension

Yes



Heart Disease

No



Smoking History

Never



BMI (Body Mass Index)

31.2

HbA1c Level (%)

7.4

Blood Glucose Level (mg/dL)

3. Ứng dụng 2: Hệ thống Định giá Bất động sản Nhà ở Hà Nội (House Price Prediction)


Link GitHub Notebook:
https://github.com/TrVHau/A2_CT_hautv.287/blob/main/house_price/notebook/house_price_prediction.ipynb
Link Kaggle Dataset: <https://www.kaggle.com/datasets/ladcva/vietnam-housing-dataset-hanoi/data>

3.1. Định nghĩa bài toán và Làm sạch Dữ liệu Bất động sản

Bài toán đặt ra là xây dựng mô hình hồi quy học máy có khả năng định giá tự động bất động sản nhà ở tại khu vực Hà Nội. Biến mục tiêu là đơn giá trên một mét vuông (Giá/m² - triệu VNĐ/m²) và tổng giá trị căn nhà (tỷ VNĐ).

Bộ dữ liệu Vietnam Housing Dataset Hanoi gồm 82,497 tin đăng giao dịch thực tế. Quá trình làm sạch dữ liệu bao gồm: chuyển đổi dữ liệu chuỗi sang định dạng số liên tục, loại bỏ các bản ghi không có thông tin diện tích hoặc đơn giá, áp dụng phân vị IQR để lọc các giá trị ngoại lệ phi lý (giữ diện tích từ 10 - 1,000 m², đơn giá từ 5 - 500 triệu/m²). Kỹ thuật trích xuất đặc trưng hình học (Feature Engineering) đã tạo thêm các biến: Tỷ lệ dài/rộng (Aspect_Ratio), Diện tích tính toán (Calculated_Area), có có kích thước (Has_Dimensions) và có pháp lý (Has_Legal_Docs).

Nhóm đặc trưng	Các biến thành phần	Xử lý trong Pipeline toán học
Đặc trưng hình học & kích thước	Area, Length, Width, Aspect_Ratio, Calculated_Area	Xử lý khuyết thiếu Median Imputer + Chuẩn hóa RobustScaler
Chỉ báo nhị phân (Binary Flags)	Has_Dimensions, Has_Legal_Docs	Chuẩn hóa RobustScaler
Đặc trưng phân loại (Categorical)	Quận, Loại hình nhà ở, Giấy tờ pháp lý, Bedrooms_Category	Mode Imputer + Mã hóa đa chiều OneHotEncoder
Biến mục tiêu (Target)	Price_per_m2 (triệu VNĐ/m ²), Total_Price (tỷ VNĐ)	Hồi quy giá trị thực liên tục $y \in \mathbb{R}^+$



Hình: Phân phối đơn giá (triệu VND/m²) và tương quan giữa Diện tích với Tổng giá trị BĐS tại Hà Nội

3.2. Biểu diễn Không gian Đặc trưng & Đóng gói Pipeline Hồi quy

Sau khi áp dụng One-Hot Encoding cho 30 đơn vị hành chính cấp Quận/Huyện, 4 loại hình nhà ở, các trạng thái pháp lý và nhóm phòng ngủ, mỗi căn nhà được ánh xạ thành một vector đặc trưng có số chiều $d = 55$:

$$\mathbf{x}_i \in \mathbb{R}^{55}, \quad \hat{y}_i = f(\mathbf{x}_i; \mathbf{w}) \in \mathbb{R}$$

Dữ liệu được phân chia thành tập huấn luyện (64,024 mẫu) và tập kiểm thử (16,007 mẫu). Pipeline hồi quy sử dụng `RobustScaler` thay vì `StandardScaler` nhằm loại bỏ ảnh hưởng của các mức giá bất thường do đầu cơ hoặc bất động sản siêu sang.

Code Snippet: Kiến trúc Pipeline Hồi quy Định giá BĐS Hà Nội

```
# Pipeline tiền xử lý và Huấn luyện mô hình Hồi quy Giá nhà
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import RobustScaler, OneHotEncoder
from sklearn.impute import SimpleImputer
from sklearn.pipeline import Pipeline
from sklearn.ensemble import RandomForestRegressor

num_cols = ['Area', 'Length', 'Width', 'Aspect_Ratio', 'Calculated_Area', 'Has_Dimensions',
            'Has_Legal_Docs']
cat_cols = ['Quận', 'Loại hình nhà ở', 'Giấy tờ pháp lý', 'Bedrooms_Category']

num_pipeline = Pipeline([
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', RobustScaler())
])

cat_pipeline = Pipeline([
    ('imputer', SimpleImputer(strategy='most_frequent')),
    ('encoder', OneHotEncoder(handle_unknown='ignore', sparse_output=False))
])

preprocessor = ColumnTransformer(transformers=[
    ('num', num_pipeline, num_cols),
    ('cat', cat_pipeline, cat_cols)
])

# Pipeline hoàn chỉnh Random Forest Regressor
hp_pipeline = Pipeline([
    ('preprocessor', preprocessor),
    ('regressor', RandomForestRegressor(n_estimators=100, max_depth=20,
```


```
] )
```

```
min_samples_split=10, random_state=42, n_jobs=-1))
```

3.3. Kết quả Thực nghiệm & Đánh giá Hiệu năng Hồi quy

Các mô hình hồi quy được so sánh trên cùng tập Test (16,007 bất động sản) dựa trên 3 chỉ số chuẩn: Sai số tuyệt đối trung bình (MAE), Căn bậc hai sai số bình phương trung bình (RMSE) và Hệ số xác định (R^2 Score):

Thuật toán Hồi quy	MAE (triệu/m ²)	MSE	RMSE (triệu/m ²)	R ² Score	Thời gian (s)
Random Forest Regressor (Selected)	23.34	1221.15	34.95	0.3729	3.42s
Gradient Boosting Regressor	25.12	1354.24	36.80	0.3410	5.18s
Decision Tree Regressor	26.85	1560.25	39.50	0.2850	0.45s
Ridge Regression (alpha=10.0)	29.40	1772.41	42.10	0.2150	0.08s
Linear Regression (OLS)	29.42	1774.09	42.12	0.2148	0.09s
Baseline Predictor (Mean)	36.80	2450.25	49.50	0.0000	0.01s



Hình: So sánh sai số MAE, RMSE và hệ số R^2 giữa các mô hình hồi quy Giá nhà Hà Nội

Đánh giá mô hình: Random Forest Regressor đạt hiệu năng vượt trội với MAE thấp nhất (23.34 triệu/m²), giảm hơn 36.6% sai số so với mô hình baseline và $R^2 = 0.3729$. Mô hình phản ánh đúng xu thế phi tuyến tính và sự tương tác phức tạp giữa vị trí địa lý với đặc điểm công trình.

3.4. Triển khai REST API & Giao diện Định giá Web/Mobile

Ứng dụng web cho phép người dùng nhập thông số căn nhà (diện tích, kích thước, quận huyện, loại hình) và nhận kết quả định giá tự động kèm khoảng giá tin cậy:

HANOI PROPTech VALUATION

Model Ready (Random Forest)

Dự đoán Giá Nhà Đất Hà Nội

Hệ thống định giá tự động (AVM) sử dụng Machine Learning Pipeline (Random Forest Regressor) được huấn luyện trên hơn 64.000 giao dịch nhà đất thực tế tại Hà Nội.

Thử nhanh BĐS mẫu:

Mặt phố Hoàn Kiếm

Biệt thự Hồ Tây

Ngõ ô tô Cầu Giấy

Ngoại thành Đông Anh

Diện tích nhà đất (m²)

(5 - 3000 m²)

Quận / Huyện

85.5

Quận Cầu Giấy

Kích thước chiều dài & mặt tiền (m)

(Tùy chọn - Dùng tính Tỷ lệ khuôn đất Aspect Ratio)

15.0

5.7

Loại hình nhà ở

Giấy tờ pháp lý

Nhà mặt phố, mặt tiền

Đã có sổ đỏ / sổ hồng

Số phòng ngủ

3 Phòng ngủ

Định Giá Bất Động Sản

Làm mới

Assignment 2 • Hanoi House Price Prediction • Random Forest Pipeline (R² = 0.373, MAE = 23.34 triệu/m²)

FastAPI Server

Hình: Giao diện Web: Form nhập đặc trưng căn nhà (Diện tích 85.5 m², Cầu Giấy, Sổ đỏ)

Thử nhanh BĐS mẫu:

Mặt phố Hoàn Kiếm

Biệt thự Hồ Tây

Ngõ ô tô Cầu Giấy

Ngoại thành Đông Anh

Diện tích nhà đất (m²)

(5 - 3000 m²)

Quận / Huyện

85.5

Quận Cầu Giấy

Kích thước chiều dài & mặt tiền (m)

(Tùy chọn - Dùng tính Tỷ lệ khuôn đất Aspect Ratio)

15.0

5.7

Loại hình nhà ở

Giấy tờ pháp lý

Nhà mặt phố, mặt tiền

Đã có sổ đỏ / sổ hồng

Số phòng ngủ

3 Phòng ngủ

Định Giá Bất Động Sản

Làm mới

ƯỚC TÍNH GIÁ TRỊ BẤT ĐỘNG SẢN

Đơn giá ước tính / m²

12.93 Tỷ VNĐ

151.24 Triệu / m²

Khoảng giá kỳ vọng (MAE ± sai số):

11.93 Tỷ — 13.93 Tỷ VNĐ

Tỷ lệ khuôn đất

Diện tích kích thước

Đầy đủ kích thước

Pháp lý đảm bảo

2.63

85.5 m²

Có (1)

Có (1)

Hình: Giao diện Web: Card hiển thị đơn giá định giá (91.25 tr/m²) và tổng giá trị (5.47 tỷ VNĐ)



HANOI PROPTech VALUATION



Model Ready (Random Forest)

Dự đoán Giá Nhà Đất Hà Nội

Hệ thống định giá tự động (AVM) sử dụng Machine Learning Pipeline (Random Forest Regressor) được huấn luyện trên hơn 64,000 giao dịch nhà đất thực tế tại Hà Nội.

 Thử nhanh BĐS mẫu:



Mật phố Hoàn Kiếm



Biệt thự Hồ Tây



Ngõ ô tô Cầu Giấy



Ngoại thành Đông Anh

Diện tích nhà đất (m²)



(5 - 3000 m²)

72.0

Quận / Huyện



Quận Cầu Giấy



Hình: Giao diện Mobile: Form định giá trên ứng dụng di động

Nhà mặt phố, mặt tiền



Giấy tờ pháp lý



Đã có sổ đỏ / sổ hồng



Số phòng ngủ



3 Phòng ngủ



**Định Giá Bất
Động Sản**

Làm mới

ƯỚC TÍNH GIÁ TRỊ BẤT ĐỘNG SẢN

12.31 Tỷ VNĐ

Đơn giá ước tính / m²

170.91 Triệu / m²

Khoảng giá kỳ vọng 11.47 Tỷ —
(MAE ± sai số): 13.15 Tỷ VNĐ



Tỷ lệ khuôn đất

2.00

Diện tích kích
thước

72.0 m²

4. Ứng dụng 3: Hệ thống Phân loại Khuyến nghị Đa phương thức (Customer Behavior)

Link GitHub Notebook:

https://github.com/TrVHau/A2_CT_hautv.287/blob/main/customer_behavior/notebook/customer_behavior.ipynb

Link Kaggle Dataset: <https://www.kaggle.com/datasets/nicapotato/womens-ecommerce-clothing-reviews>


4.1. Định nghĩa bài toán & Hướng tiếp cận Multimodal Fusion

Mục tiêu bài toán là dự đoán hành vi khách hàng có sẵn sàng khuyến nghị sản phẩm thời trang cho người khác hay không (biến mục tiêu `Recommended IND` $\in \{0, 1\}$).

Điểm đột phá trong nghiên cứu này là áp dụng kiến trúc Kết hợp đa phương thức (Multimodal Feature Fusion):

- **1. Tabular Modality:** Nhánh Dữ liệu Dạng bảng (Tabular Modality): Khai thác 8 đặc trưng cấu trúc gồm Age, Rating, Positive Feedback Count, Review Length, Word Count, Has Title và các danh mục phân cấp ngành hàng (Division, Department, Class Name) qua StandardScaler và OneHotEncoder (d_tab = 38 chiều).
- **2. Text Modality:** Nhánh Xử lý Ngôn ngữ Tự nhiên (Text Modality): Ghép nối tiêu đề và bài viết đánh giá thành chuỗi văn bản hoàn chỉnh, làm sạch ký tự đặc biệt, chuyển chữ thường và trích xuất không gian vector ngữ nghĩa bằng TfidfVectorizer(max_features=1000, ngram_range=(1,2)) (d_text = 1,000 chiều).

Nhánh phương thức	Đặc trưng đầu vào	Phương pháp Vector hóa	Số chiều d
Tabular - Số liên tục	Age, Rating, Positive Feedback, review_length, word_count	StandardScaler	5 chiều
Tabular - Cờ nhị phân	has_title (Có tiêu đề hay không)	Passthrough (Binary)	1 chiều
Tabular - Phân loại	Division Name, Department Name, Class Name	OneHotEncoder(handle_unknown='ignore')	32 chiều
Text - Ngôn ngữ tự nhiên	full_text = Title + ' ' + Review Text	TfidfVectorizer(1000, ngram=(1,2), stop_words)	1,000 chiều
Multimodal Concatenation	Toàn bộ thông tin thực thể khách hàng & bài đánh giá	Hợp nhất không gian vector (ColumnTransformer)	1,038 chiều



Hình: Phân phối nhãn Recommended IND trên 23,486 đánh giá thương mại điện tử

4.2. Pipeline Hợp nhất Đa phương thức & Mô hình Huấn luyện

Tổng không gian vector đặc trưng sau khi hợp nhất đạt $d = 1,038$ chiều: $\mathbf{x}_i = [\mathbf{x}_{\text{tab}}, \mathbf{x}_{\text{text}}]^T \in \mathbb{R}^{1038}$. Toàn bộ tiền xử lý được tích hợp trong một ColumnTransformer duy nhất:

Code Snippet: Xây dựng Multimodal Feature Fusion Pipeline trong Scikit-Learn

```
# Kiến trúc Multimodal Fusion Pipeline cho Customer Behavior
from sklearn.compose import ColumnTransformer
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LogisticRegression

# 1. Định nghĩa các nhánh xử lý
tabular_num_cols = ['Age', 'Rating', 'Positive Feedback Count', 'review_length', 'word_count',
                    'has_title']
tabular_cat_cols = ['Division Name', 'Department Name', 'Class Name']
text_col = 'full_text'


preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), tabular_num_cols),
        ('cat', OneHotEncoder(handle_unknown='ignore', sparse_output=True), tabular_cat_cols),
        ('text', TfidfVectorizer(max_features=1000, ngram_range=(1,2), stop_words='english'),
         text_col)
    ]
)

# 2. Pipeline Multimodal Logistic Regression Balanced
multimodal_pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('classifier', LogisticRegression(class_weight='balanced', max_iter=1000, random_state=42))
])
```

4.3. Đánh giá Đối chiếu 3 Hướng tiếp cận (Tabular vs Text vs Multimodal)


Nhóm tiến hành thực nghiệm so sánh độc lập giữa 3 trường phái biểu diễn dữ liệu trên 4,698 mẫu kiểm thử:

Hướng tiếp cận	Mô hình phân loại	Accurac y	Precision	Recall	F1-Score	ROC- AUC
Multimodal Fusion	Logistic Regression (Balanced)	93.33%	98.71%	93.11%	95.83%	0.9772
Multimodal Fusion	LinearSVC (Calibrated)	93.25%	95.06%	96.81%	95.93%	0.9735
Multimodal Fusion	Random Forest Classifier	93.07%	98.76%	92.74%	95.66%	0.9692
Tabular-Only	Logistic Regression	93.16%	98.79%	92.82%	95.71%	0.9720
Tabular-Only	Random Forest Classifier	93.12%	98.71%	92.85%	95.69%	0.9655
Text-Only (NLP)	LinearSVC (Calibrated)	89.84%	91.49%	96.63%	93.99%	0.9218
Text-Only (NLP)	Logistic Regression	86.62%	95.75%	87.61%	91.50%	0.9268



Hình: So sánh chỉ số F1, Recall, Precision và ROC-AUC giữa 3 hướng tiếp cận

Biểu đồ 2: Biểu đồ Radar so sánh Tabular vs Text vs Multimodal



Hình: Radar Chart đánh giá hiệu năng toàn diện đa chiều của các mô hình

Kết luận đánh giá: Hướng tiếp cận Multimodal Fusion đạt hiệu năng cao nhất, trong đó Logistic Regression Balanced đạt ROC-AUC = 0.9772 và F1 = 95.83%. Mô hình có ưu thế vượt trội về khả năng giải thích (Interpretable AI) qua trọng số từ khóa TF-IDF và thời gian suy luận cực nhanh (dưới 5ms/request).

4.4. Triển khai REST API & Giao diện Web/Mobile

E-COMMERCE ANALYTICS

Model Ready

Customer Behavior & Review Recommendation

Hệ thống AI Multimodal dự đoán mức độ hài lòng và quyết định sẵn sàng khuyến nghị (Recommendation) sản phẩm thời trang nữ dựa trên đánh giá văn bản và thông tin khách hàng.

⚡ Thử nhanh dữ liệu mẫu:

★ Đánh giá Tích cực (5 Sao)

⚠ Đánh giá Tiêu cực (1 Sao)

📊 Đánh giá Trung bình (3 Sao)

Độ tuổi khách hàng (Age)

29

(18 - 100)

Đánh giá xếp hạng (Rating)

★★★★★ 5 Sao

Số lượt thích nhận xét (Feedback Count)

18

(≥ 0)

Phân nhóm (Division Name)

General

Ngành hàng (Department Name)

Dresses

Danh mục chi tiết (Class Name)

Dresses

Tiêu đề đánh giá (Review Title)

Absolutely loved this elegant dress!

(Tùy chọn)

Nội dung nhận xét chi tiết (Review Text)

The fabric quality is outstanding, stitching is exquisite and the fit was true to size. I received so many compliments at the party!

Độ dài: 169 ký tựSố từ: 28 từ

Hình: Giao diện Web: Form nhập thông tin đánh giá sản phẩm (Chụp từ App đang chạy)

29

★★★★★ 5 Sao

Số lượt thích nhận xét (Feedback Count)

18

(≥ 0)

Phân nhóm (Division Name)

General

Ngành hàng (Department Name)

Dresses

Danh mục chi tiết (Class Name)

Dresses

Tiêu đề đánh giá (Review Title)

Absolutely loved this elegant dress!

(Tùy chọn)

Nội dung nhận xét chi tiết (Review Text)

The fabric quality is outstanding, stitching is exquisite and the fit was true to size. I received so many compliments at the party!

Độ dài: 169 ký tựSố từ: 28 từ

Phân tích & Dự đoán Khuyến nghị

Làm mới

🎯 SẴN SÀNG KHUYẾN NGHỊ (RECOMMENDED)

Độ tin cậy: 98.8%

Khuyến nghị (P = 1)

98.8%

Không khuyến nghị (P = 0)

1.2%

169

Độ dài văn bản (chars)

28

Tổng số từ (words)

Có

Có tiêu đề (has_title)

Hình: Giao diện Web: Thẻ kết quả 'SẴN SÀNG KHUYẾN NGHỊ' với độ tin cậy 99.7%

★★★★★ 5 Sao

Số lượt thích nhận xét (Feedback Count) (≥ 0)

15

Phân nhóm (Division Name) *

General

Ngành hàng (Department Name) *

Dresses

Danh mục chi tiết (Class Name) *

Dresses

Tiêu đề đánh giá (Review Title) (Tùy chọn)

Love the material and fit!

Nội dung nhận xét chi tiết (Review Text) *

Fits perfectly and feels so soft. Color is exactly as pictured, would highly recommend!

Độ dài: 114 ký tự Số từ: 19 từ



Phân tích & Dự
đoán Khuyến nghị

Làm mới

Hình: Giao diện Mobile: Nhập nhận xét thời trang trên điện thoại

Tiêu đề đánh giá (Review Title) (Tùy chọn)

Love the material and fit!

Nội dung nhận xét chi tiết (Review Text) *

Fits perfectly and feels so soft. Color is exactly as pictured, would highly recommend!

Độ dài: 114 ký tự Số từ: 19 từ



Phân tích & Dự đoán Khuyến nghị

Làm mới



SẴN SÀNG KHUYẾN NGHỊ (RECOMMENDED)

Độ tin cậy: 99.6%

Khuyến nghị (P = 1) 99.6%

Không khuyến nghị (P = 0) 0.4%

114

Độ dài văn bản (chars)

19

5. Phân tích So sánh & Đối chiếu Ba Hệ thống Thông minh

Bảng dưới đây tổng hợp đối chiếu toàn diện 3 hệ thống học máy về các khía cạnh kỹ thuật then chốt:

Khía cạnh kỹ thuật	1. Diabetes Screening	2. House Price Valuation	3. Customer Recommendation
Bài toán & Miền dữ liệu	Phân loại nhị phân Y tế	Hồi quy Bất động sản	Phân loại nhị phân Đa phương thức TMĐT
Đối tượng một quan sát	Một bệnh nhân	Một tin đăng căn nhà	Một bài nhận xét sản phẩm thời trang
Không gian đặc trưng x_i	$x \in \mathbb{R}^{15}$ (6 số + 9 OHE)	$x \in \mathbb{R}^{55}$ (7 số + 48 OHE)	$x \in \mathbb{R}^{1,038}$ (38 Tabular + 1,000 TF-IDF)
Chiến lược Tiền xử lý	StandardScaler + OneHotEncoder	RobustScaler + Median Imputer + OHE	StandardScaler + OHE + TF-IDF Vectorizer
Mô hình được chọn	Random Forest Classifier	Random Forest Regressor	Logistic Regression (Balanced)
Tiêu chí đánh giá chính	Recall, F1-Score, ROC-AUC	MAE, RMSE, R ² Score	F1-Score, Precision, ROC-AUC
Rủi ro dữ liệu thực tế	Mất cân bằng nhãn; Bỏ sót ca bệnh (FN)	Ngoại lệ giá cao; Thiếu tọa độ GPS	Mất cân bằng nhãn; Đánh giá ngắn/nhiều
Artifact đóng gói	diabetes_pipeline.joblib (18.3 MB)	house_price_model.pkl (44.8 MB)	customer_behavior_pipeline.joblib (50 KB)
Công nghệ Web / API	FastAPI + Uvicorn + HTML5 Client	FastAPI + Uvicorn + HTML5 Client	FastAPI + Uvicorn + HTML5 Client

6. Khả năng Tái lập, Thảo luận & Hạn chế của Hệ thống

6.1. Đảm bảo Tính Tái lập Thực nghiệm (Reproducibility)

- 1. Random Seed:** Cố định hạt giống ngẫu nhiên: Mọi bước phân chia dữ liệu (train_test_split) và khởi tạo mô hình đều cố định RANDOM_STATE = 42.
- 2. Anti-Leakage Architecture:** Đóng gói Pipeline nguyên khối: Toàn bộ quá trình tiền xử lý được fit duy nhất trên tập Train và đóng gói cùng bộ phân loại thành file artifact (.joblib/.pkl). Khi API nhận

dữ liệu mới, pipeline chỉ gọi hàm `.transform()` mà không fit lại, ngăn chặn tuyệt đối rủi ro Data Leakage.

- **3. Codebase & Environment:** Mã nguồn mở và chuẩn hóa môi trường: Toàn bộ code notebook, backend và frontend được quản lý phiên bản trên Git repository [https://github.com/TrVHau/A2_CT_hautv.287](https://github.com/TrVHau/A2_CT_hautv.287) với môi trường Python 3.11 Conda độc lập.

6.2. Thảo luận về Giới hạn Thực tế của Hệ thống

- **1. Y tế:** Diabetes Prediction: Dù đạt ROC-AUC 0.9738, mô hình vẫn tồn tại 13.2% False Negatives. Dự đoán chỉ mang giá trị cảnh báo sớm hỗ trợ bác sĩ sàng lọc, tuyệt đối không thay thế xét nghiệm chẩn đoán y khoa chuyên sâu.
- **2. Bất động sản:** House Price Prediction: R^2 đạt 0.3729 do dữ liệu tin đăng thiếu các biến không gian then chốt (tọa độ GPS chính xác, khoảng cách tới trường học/bệnh viện, tình trạng pháp lý quy hoạch).
- **3. Thương mại điện tử:** Customer Behavior Prediction: Dữ liệu bị mất cân bằng (82.2% nhãn tích cực) và thiếu định danh khách hàng (Customer ID) theo chuỗi thời gian, do đó mô hình chỉ phân loại cảm xúc ở cấp độ từng bài đánh giá đơn lẻ.

7. Kết luận & Bài học Kinh nghiệm

Qua quá trình nghiên cứu và phát triển hoàn chỉnh ba hệ thống máy học thông minh trong Assignment 02, nhóm rút ra các kết luận và bài học kỹ thuật quan trọng:

- **1. Tầm quan trọng của Biểu diễn dữ liệu (Data Representation):** Biểu diễn dữ liệu quyết định thành công của hệ thống: Mô hình học máy không làm việc trực tiếp với file văn bản hay bảng tính CSV thô. Việc lựa chọn phương pháp biểu diễn số học phù hợp (Z-Score cho y tế, RobustScaler cho BĐS có ngoại lệ, TF-IDF n-gram cho văn bản) đóng vai trò nền tảng quyết định chất lượng dự đoán.
- **2. Lựa chọn Mô hình & Chỉ số Đánh giá phù hợp:** Đánh giá mô hình phải gắn liền với bản chất bài toán: Không thể chỉ dựa vào Accuracy khi dữ liệu mất cân bằng. Trong y tế, Recall là ưu tiên số 1 để tránh bỏ sót bệnh nhân; trong thương mại điện tử, F1 và ROC-AUC giúp cân bằng giữa độ chính xác và độ bao quát.
- **3. Chuẩn hóa Pipeline Triển khai:** Tách bạch kiến trúc Client - Server trong triển khai công nghiệp: Việc đóng gói toàn bộ chuỗi tiền xử lý và mô hình vào Pipeline artifact giúp tách biệt hoàn toàn tầng thuật toán với tầng giao diện (Web/Mobile), đảm bảo tính nhất quán giữa lúc huấn luyện và khi triển khai thực tế.